دانشکده مهندسی کامپیوتر

استاد: دکتر ناصر مزینی

نیمسال اول ۱۴۰۵

یادگیری ماشین

تمرین سری اول

مهدی عسگری ، ستاره توکلی

تاریخ انتشار: ۲۵ مهر ماه

تاریخ تحویل: ۲ آبان ماه

قوانین و مقررات انجام و تحویل تمارین

۱. پاسخ سوالات را به صورت کامل باتوجه به نوع و شماره هر سوال در قالب گزارش PDF در یک فایل فشرده به شکل زیر قرار داده و تا زمان تعیین شده در LMS بارگذاری نمایید.

HW-[Number]-[Name]-[LastName]-[StudentID].zip

۲. در مجموع کل ترم به میزان یک هفته تاخیر در تمارین مجاز است و از نمره شما کسر نخواهد شد.

۳. لطفا منابع استفاده شده شامل هرگونه منبع (کد، مقاله، کتاب، صفحه وب و...) در حل هر سوال را ذکر نمایید. از نظر اخلاقی نیز استفاده از منبع بدون ارجاع، سرقت علمی به حساب می‌آید.

۴. تمرین باید به صورت انفرادی انجام شوند و حل گروهی مجاز نیست. در صورت وجود هرگونه مشابهت نمره طرفین (۱۰۰-) درنظر گرفته خواهد شد.

۵. استفاده از مدل‌های زبانی هوش مصنوعی صرفا باید در جهت کمک به فهم دقیق‌تر سوالات باشد. در نهایت تحلیل خود را به عنوان پاسخ بنویسید.

۶. پس از حل سوالات عملی، لطفاً فایل کد خود را به همراه یک ویدیو که در آن مراحل پیاده‌سازی و اجرای پروژه را توضیح می‌دهید، ارسال کنید.

۱ سوالات

۱. سوال اول: تحلیل تابع هزینه و گرادیان در رگرسیون

- در یک مسئله رگرسیون خطی، فرض کنید از تابع هزینه میانگین مربعات خطا[۱] استفاده می‌کنیم. اگر یکی از داده‌های آموزشی ما دارای یک نقطه پرت[۲] بسیار بزرگ باشد، توضیح دهید این نقطه چه تأثیری بر روی شیب (w) و عرض از مبدأ (b) خط رگرسیون نهایی می‌گذارد؟
- چرا تابع هزینه میانگین مربعات خطا نسبت به خطاهای بزرگ‌تر به صورت غیرخطی حساس‌تر است؟

۲. سوال دوم: هم‌خطی و ضریب تعیین R^2

- در یک مدل رگرسیون چندگانه، مهندسی داده‌ها را انجام داده‌ایم و متوجه می‌شویم که دو ویژگی ورودی X_1 و X_2 دارای ضریب همبستگی نزدیک به ۱ با یکدیگر هستند (پدیده هم‌خطی چندگانه[۳]).
- با اینکه مدل نهایی همچنان ممکن است ضریب تعیین (R^2) قابل قبولی روی داده‌های آموزشی داشته باشد، چرا تفسیرپذیری ضرایب (C_1 و C_2) توسط کارشناس کسب‌وکار عملاً غیرقابل اعتماد و خطرناک می‌شود؟
- این پدیده چه تأثیری روی واریانس ضرایب تخمین‌زده‌شده می‌گذارد؟

۳. سوال سوم: توازن بایاس و واریانس در مدل‌های رگرسیون

- دانش‌آموزی برای پیش‌بینی قیمت مسکن، یک مدل رگرسیون چندجمله‌ای با درجه بسیار بالا[۴] پیاده‌سازی کرده است. وضعیت خطای آموزش و خطای آزمون در این مدل چگونه خواهد بود؟
- اگر حجم داده‌های آموزشی را در این مدلِ بسیار پیچیده، به طور چشمگیری افزایش دهیم (مثلاً ۱۰ برابر کنیم)، آیا این کار به‌تنهایی می‌تواند مشکل بیش‌برازش[۵] را به‌طور کامل حل کند؟ چرا؟

۴. سوال چهارم: مفاهیم نرم‌ها در رگرسیون (L_1 در برابر L_2)

---

[۱] MSE
[۲] Outlier
[۳] Multicollinearity
[۴] High-Degree Polynomial
[۵] Overfitting

- می‌دانیم در رگرسیون‌های منظم‌شده (مانند ریج[۶] و لاسو[۷])، نوع جریمه‌ای که به تابع هزینه اضافه می‌شود بر اساس نرم‌های L_1 و L_2 است.
- از نظر هندسی و مشتق‌پذیری، چرا جریمه نرم L_1 (لاسو) این توانایی را دارد که ضریب برخی ویژگی‌های غیرمهم را دقیقاً برابر با صفر کند (انتخاب ویژگی)، در حالی که نرم L_2 (ریج) ضرایب را کوچک می‌کند اما صفر نمی‌کند؟

۵. سوال پنجم: اعتبارسنجی متقاطع و نشت داده

- یک تیم مدل‌سازی پیش از شروع اعتبارسنجی متقاطع مبتنی بر کی-فولد[۸]، کل مجموعه داده را با استفاده از استانداردساز[۹] مقیاس‌بندی می‌کند و سپس فرآیند کی-فولد[۱۰] را اجرا می‌کند. آیا این روش از نظر علمی درست است؟
- اگر پاسخ خیر است، پدیده‌ای به نام نشت داده[۱۱] چگونه در اینجا رخ داده و چه تأثیری بر خطای ارزیابی نهایی مدل می‌گذارد؟

۶. سوال ششم: تفسیر مقیاس و ویژگی‌های ساختگی

- اگر در یک مدل رگرسیون خطی ساده پیش‌بینی قیمت، فراموش کنیم ویژگی‌های ورودی را مقیاس‌بندی[۱۲] کنیم و مقیاس یکی از ویژگی‌ها (مثلاً درآمد بر حسب دلار) هزار برابر بزرگ‌تر از ویژگی دیگر (مثلاً تعداد اتاق‌ها) باشد، آیا قدرت پیش‌بینی نهایی مدل روی داده‌های تست به‌شدت افت می‌کند؟ (چرا رگرسیون خطی استاندارد نسبت به مقیاس ویژگی‌ها در پیش‌بینی مقاوم است؟)
- اما عدم مقیاس‌بندی دقیقاً چه زمانی برای مدل ما فاجعه‌بار می‌شود؟ (به الگوریتم‌های بهینه‌سازی مثل گرادیان کاهشی[۱۳] یا منظم‌سازی اشاره کنید).

۷. سوال هفتم: پروژه عملی و پیاده‌سازی خط لوله رگرسیون

- فایل کدمسیر `practical.ipynb` را دریافت کرده و بخش‌های ناقص آن (TODO) را بر اساس اصول آماری و یادگیری ماشین تکمیل کنید.

---

[۶] Ridge
[۷] Lasso
[۸] k-Fold Cross-Validation
[۹] StandardScaler
[۱۰] K-Fold
[۱۱] Data Leakage
[۱۲] Scaling
[۱۳] Gradient Descent

نکات تکمیلی تمرین

۲ نحوه نوشتار و حل تمرین

۱. پاسخ‌ها باید کامل، دقیق و خوانا باشند. از توضیحات مختصر و مفید استفاده کنید و در صورت نیاز، مثال بزنید.

۲. مراحل حل تمرین را به ترتیب و با رعایت منطق بیان کنید. از حذف گام‌های میانی خودداری کنید.

۳. در سوالات محاسباتی، تمامی فرمول‌ها و مراحل را ذکر کنید. تنها نوشتن جواب نهایی کافی نیست.

۴. در سوالات تشریحی، پاسخ‌ها باید علمی و مستدل باشند و از واژگان مناسب استفاده شود.

۵. در رسم نمودارها، شکل‌ها و جداول، دقت کنید که تمامی اجزا برچسب‌گذاری شده باشند.

۳ نکات مربوط به سایز و نوع فونت

۱. برای تایپ متن از فونت استاندارد (مانند IR Nazanin یا Times New Roman) استفاده کنید.

۲. اندازه‌ی فونت متن اصلی: ۱۴ برای فارسی و ۱۲ برای انگلیسی.

۳. اندازه‌ی فونت تیترها: حداقل ۱۶ و حداکثر ۱۸، با ضخامت **(Bold)**.

۴. فاصله بین خطوط: ۱.۵ برای خوانایی بهتر.

۵. حاشیه صفحات: ۲.۵ سانتی‌متر از هر طرف.

۶. شماره‌گذاری صفحات: در پایین صفحه و وسط قرار گیرد.

۷. در استفاده از معادلات ریاضی، از فرمت استاندارد ریاضی مانند LaTeX یا Equation Editor در Word استفاده کنید.